

2021 年春季学期/数理统计/第八周/课后作业解答

龚梓阳

更新：2021 年 5 月 3 日

2 证明. (a). 样本 x_1, x_2, \dots, x_n 的似然函数为

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n c\theta^c x_i^{-(c+1)} \mathbf{I}_{x_i > \theta} \\ &= c^n \theta^{nc} \prod_{i=1}^n x_i^{-(c+1)} \mathbf{I}_{x_1, x_2, \dots, x_n > \theta} \end{aligned}$$

$c^n \theta^{nc} \prod_{i=1}^n x_i^{-(c+1)}$ 关于 θ 单调递增, 且由于示性函数的限制, 仅当 $x_1, x_2, \dots, x_n > \theta$ 时, $L(\theta) > 0$. 因此, $\theta = \min \{x_1, x_2, \dots, x_n\} = x_{(1)}$ 时, $L(\theta)$ 达到最大。

故 θ 的最大似然估计为 $\hat{\theta} = X_{(1)}$ 。

(b). 样本 x_1, x_2, \dots, x_n 的似然函数为

$$\begin{aligned} L(\theta, \mu) &= \prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i - \mu}{\theta}} \mathbf{I}_{x_i > \mu} \\ &= \frac{1}{\theta^n} e^{-\frac{1}{\theta} (\sum_{i=1}^n x_i - n\mu)} \mathbf{I}_{x_1, x_2, \dots, x_n > \mu} \end{aligned}$$

当 $x_1, x_2, \dots, x_n > \mu$ 时,

$$\ln L(\theta, \mu) = -n \ln \theta - \frac{1}{\theta} \left(\sum_{i=1}^n x_i - n\mu \right)$$

对于给定的 θ_0 ,

$$\frac{\partial \ln L(\theta_0, \mu)}{\partial \mu} = \frac{n}{\theta_0} > 0$$

$\ln L(\theta_0, \mu)$ 关于 μ 单调递增, 且由于示性函数的限制, 仅当 $x_1, x_2, \dots, x_n > \mu$ 时, $\ln L(\theta_0, \mu) > 0$, 因此, $\mu = \min \{x_1, x_2, \dots, x_n\} = x_{(1)}$ 时, $\ln L(\theta_0, \mu)$ 达到最大。

因此, 令

$$\frac{\partial \ln L(\theta, \hat{\mu})}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \left(\sum_{i=1}^n x_i - n\hat{\mu} \right) = 0$$

解得 $\theta = \frac{1}{n} (\sum_{i=1}^n x_i - n\hat{\mu}) = \bar{x} - \hat{\mu} = \bar{x} - x_{(1)}$ 。

故 μ 的极大似然估计为 $\hat{\mu} = X_{(1)}$, θ 的极大似然估计为 $\bar{X} - X_{(1)}$ 。

(c). 样本 x_1, x_2, \dots, x_n 的似然函数为

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n (k\theta)^{-1} \mathbf{I}_{\theta < x_i < (k+1)\theta} \\ &= (k\theta)^{-n} \mathbf{I}_{\theta < x_1, x_2, \dots, x_n < (k+1)\theta} \end{aligned}$$

$(k\theta)^{-n}$ 关于 θ 单调递减, 且由于示性函数的限制, 仅当 $\theta < x_1, x_2, \dots, x_n < (k+1)\theta$ 时, $L(\theta) > 0$ 。因此, $\theta = \frac{1}{k+1} \max \{x_1, x_2, \dots, x_n\} = \frac{x_{(n)}}{k+1}$ 时, $L(\theta)$ 达到最大。故 θ 的最大似然估计为 $\hat{\theta} = \frac{X_{(n)}}{k+1}$ 。

3 证明. (a). 样本 x_1, x_2, \dots, x_n 的似然函数为

$$L(\theta) = \prod_{i=1}^n \frac{1}{2\theta} e^{-\frac{|x_i|}{\theta}} = \frac{1}{2^n \theta^n} e^{\frac{1}{\theta} \sum_{i=1}^n |x_i|}$$

其对数似然函数为

$$\ln L(\theta) = -n \ln 2 - n \ln \theta - \frac{1}{\theta} \sum_{i=1}^n |x_i|$$

令

$$\frac{\partial \ln L(\theta)}{\partial \theta} = -n \frac{1}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n |x_i| = 0$$

解得 $\theta = \frac{1}{n} \sum_{i=1}^n |x_i|$ 。

同时, 由于,

$$\begin{aligned} \left. \frac{\partial^2 \ln L(\theta)}{\partial \theta^2} \right|_{\theta = \frac{1}{n} \sum_{i=1}^n |x_i|} &= \left(\frac{n}{\theta^2} - \frac{2 \sum_{i=1}^n |x_i|}{\theta^3} \right) \bigg|_{\theta = \frac{1}{n} \sum_{i=1}^n |x_i|} \\ &= -\frac{n^3}{(\sum_{i=1}^n |x_i|)^2} < 0 \end{aligned}$$

故 θ 的最大似然估计为 $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n |x_i|$ 。

(b). 样本 x_1, x_2, \dots, x_n 的似然函数为

$$L(\theta) = \prod_{i=1}^n I_{\theta - \frac{1}{2} < x_i < \theta + \frac{1}{2}} = I_{\theta - \frac{1}{2} < x_1, x_2, \dots, x_n < \theta + \frac{1}{2}}$$

$L(\theta)$ 仅存在两个取值 0 和 1, 且当 $x_{(n)} - \frac{1}{2} < \theta < x_{(1)} + \frac{1}{2}$ 时, 有 $L(\theta) = 1$ 。

故 θ 的最大似然估计为 $\hat{\theta}$ 是 $(X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2})$ 中任何一个值。

(c). 样本 x_1, x_2, \dots, x_n 的似然函数为

$$\begin{aligned} L(\theta_1, \theta_2) &= \prod_{i=1}^n \frac{1}{\theta_2 - \theta_1} I_{\theta_1 < x_i < \theta_2} \\ &= \frac{1}{(\theta_2 - \theta_1)^n} I_{\theta_1 < x_1, x_2, \dots, x_n < \theta_2} \end{aligned}$$

显然 θ_1 越大且 θ_2 越小时, $\frac{1}{(\theta_2 - \theta_1)^n}$ 越大, 且由于示性函数的限制, 仅当 $\theta_1 < x_1, x_2, \dots, x_n < \theta_2$ 时, $L(\theta_1, \theta_2) > 0$ 。因此, $\theta_1 = \min \{x_1, x_2, \dots, x_n\} = x_{(1)}$, $\theta_2 = \max \{x_1, x_2, \dots, x_n\} = x_{(n)}$ 时, $L(\theta_1, \theta_2)$ 达到最大。

故 θ_1 的最大似然估计为 $\hat{\theta}_1 = X_{(1)}$, θ_2 的最大似然估计为 $\hat{\theta}_2 = X_{(n)}$ 。

5 证明. 当 $m = 2$ 时, X 只能取值 1 或 2, 且

$$\begin{aligned} P(X = 1) &= \frac{2p(1-p)}{1 - (1-p)^2} = \frac{2-2p}{2-p} \\ P(X = 2) &= \frac{p^2}{1 - (1-p)^2} = \frac{p}{2-p} \end{aligned}$$

因此,

$$P(X=x;p) = \left(\frac{2-2p}{2-p}\right)^{2-x} \left(\frac{p}{2-p}\right)^{x-1} = \frac{(2-2p)^{2-x} p^{x-1}}{2-p}, \quad x=1,2$$

样本 x_1, x_2, \dots, x_n 的似然函数为

$$L(p) = \prod_{i=1}^n \frac{(2-2p)^{2-x_i} p^{x_i-1}}{2-p} = \frac{(2-2p)^{2n-\sum_{i=1}^n x_i} p^{\sum_{i=1}^n x_i - n}}{(2-p)^n}$$

其对数似然函数为

$$\ln L(p) = \left(2n - \sum_{i=1}^n x_i\right) \cdot \ln(2-2p) + \left(\sum_{i=1}^n x_i - n\right) \cdot \ln p - n \ln(2-p)$$

令

$$\frac{\partial \ln L(p)}{\partial p} = \left(2n - \sum_{i=1}^n x_i\right) \cdot \frac{-2}{2-2p} + \left(\sum_{i=1}^n x_i - n\right) \cdot \frac{1}{p} - n \cdot \frac{-1}{2-p} = 0$$

解得

$$p = 2 - \frac{2n}{\sum_{i=1}^n x_i} = 2 - \frac{2}{\bar{x}}$$

故 p 的最大似然估计为 $\hat{p} = 2 - \frac{2}{\bar{X}}$ 。

7 证明. (a). 因为 $X \sim U(\theta, 2\theta)$, 有,

$$E(X) = \frac{\theta + 2\theta}{2} = \frac{3}{2}\theta, \quad \text{Var}(X) = \frac{(2\theta - \theta)^2}{12} = \frac{1}{12}\theta^2$$

故,

$$E(\hat{\theta}) = \frac{2}{3}E(\bar{X}) = \frac{2}{3}E(X) = \frac{2}{3} \cdot \frac{3}{2}\theta = \theta$$

即 $\hat{\theta} = \frac{2}{3}\bar{X}$ 是参数 θ 的无偏估计;

同时, 因

$$\text{Var}(\hat{\theta}) = \frac{4}{9} \text{Var}(\bar{X}) = \frac{4}{9n} \text{Var}(X) = \frac{4}{9n} \cdot \frac{1}{12}\theta^2 = \frac{\theta^2}{27n}$$

有,

$$\lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta, \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}) = 0$$

故 $\hat{\theta} = \frac{2}{3}\bar{X}$ 是参数 θ 的相合估计。

(b). 样本 x_1, x_2, \dots, x_n 的似然函数为

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbf{I}_{\theta < x_i < 2\theta} = \frac{1}{\theta^n} \mathbf{I}_{\theta < x_1, x_2, \dots, x_n < 2\theta}$$

$\frac{1}{\theta^n}$ 关于 θ 单调递减, 且由于示性函数的限制, 仅当 $\theta < x_1, x_2, \dots, x_n < 2\theta$ 时, $L(\theta) > 0$ 。

因此, $\theta = \frac{1}{2} \max \{x_1, x_2, \dots, x_n\} = \frac{1}{2}x_{(n)}$ 时, $L(\theta)$ 达到最大。

故 θ 的最大似然估计为 $\hat{\theta}_{\text{MLE}} = \frac{1}{2}X_{(n)}$ 。

由于 X 的密度函数与分布函数为

$$p(x) = \begin{cases} \frac{1}{\theta}, & \theta < x < 2\theta \\ 0, & \text{其他} \end{cases} \quad F(x) = \begin{cases} 0, & x < \theta \\ \frac{x-\theta}{\theta}, & \theta \leq x < 2\theta; \\ 1, & x \geq 2\theta. \end{cases}$$

则 $X_{(n)}$ 的密度函数为

$$p_n(x) = n[F(x)]^{n-1}p(x) = \begin{cases} \frac{n(x-\theta)^{n-1}}{\theta^n}, & \theta < x < 2\theta \\ 0, & \text{其他} \end{cases}$$

所以,

$$E(X_{(n)} - \theta) = \int_{\theta}^{2\theta} (x - \theta) \cdot \frac{n(x - \theta)^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \cdot \frac{(x - \theta)^{n+1}}{n+1} \Big|_{\theta}^{2\theta} = \frac{n}{n+1}\theta$$

有,

$$E(X_{(n)}) = \frac{2n+1}{n+1}\theta$$

$$E[(X_{(n)} - \theta)^2] = \int_{\theta}^{2\theta} (x - \theta)^2 \cdot \frac{n(x - \theta)^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \cdot \frac{(x - \theta)^{n+2}}{n+2} \Big|_{\theta}^{2\theta} = \frac{n}{n+2}\theta^2$$

有,

$$\text{Var}(X_{(n)}) = \text{Var}(X_{(n)} - \theta) = \frac{n}{n+2}\theta^2 - \left(\frac{n}{n+1}\theta\right)^2 = \frac{n}{(n+1)^2(n+2)}\theta^2$$

又由于, $\hat{\theta}_{\text{MLE}} = \frac{1}{2}X_{(n)}$

$$\begin{aligned} E(\hat{\theta}_{\text{MLE}}) &= \frac{1}{2}E(X_{(n)}) = \frac{2n+1}{2(n+1)}\theta \neq \theta \\ \text{Var}(\hat{\theta}_{\text{MLE}}) &= \frac{1}{4}\text{Var}(X_{(n)}) = \frac{n}{4(n+1)^2(n+2)}\theta^2 \end{aligned}$$

故 $\hat{\theta}_{\text{MLE}} = \frac{1}{2}X_{(n)}$ 不是参数 θ 的无偏估计。

因为,

$$\begin{aligned} \lim_{n \rightarrow \infty} E(\hat{\theta}_{\text{MLE}}) &= \lim_{n \rightarrow \infty} \frac{2n+1}{2(n+1)}\theta = \theta \\ \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_{\text{MLE}}) &= \lim_{n \rightarrow \infty} \frac{n}{4(n+1)^2(n+2)}\theta^2 = 0 \end{aligned}$$

故 θ 的最大似然估计 $\hat{\theta}_{\text{MLE}} = \frac{1}{2}X_{(n)}$ 是参数 θ 的相合估计。

8 证明. (a). 样本 x_1, x_2, \dots, x_n 的似然函数为

$$L(\theta) = \prod_{i=1}^n e^{-(x_i - \theta)} I_{x_i > \theta} = \exp\left(-\sum_{i=1}^n x_i + n\theta\right) I_{x_1, x_2, \dots, x_n > \theta}$$

$\exp(-\sum_{i=1}^n x_i + n\theta)$ 关于 θ 单调递增, 且由于示性函数的限制, 仅当 $x_1, x_2, \dots, x_n > \theta$ 时, $L(\theta) > 0$ 。因此, $\theta = \min\{x_1, x_2, \dots, x_n\} = x_{(1)}$ 时, $L(\theta)$ 达到最大。

故 θ 的最大似然估计为 $\hat{\theta}_1 = X_{(1)}$ 。

由于 X 的密度函数与分布函数为

$$p(x) = \begin{cases} e^{-(x-\theta)}, & x > \theta \\ 0, & x \leq \theta \end{cases} \quad F(x) = \begin{cases} 1 - e^{-(x-\theta)}, & x > \theta \\ 0, & x \leq \theta \end{cases}$$

则 $X_{(1)}$ 的密度函数为

$$p_1(x) = n[1 - F(x)]^{n-1}p(x) = \begin{cases} ne^{-n(x-\theta)}, & x > \theta \\ 0, & x \leq \theta. \end{cases}$$

可得 $X_{(1)} - \theta$ 服从指数分布 $\text{Exp}(n)$ 。

所以,

$$E(X_{(1)} - \theta) = \frac{1}{n}, \quad \text{Var}(X_{(1)} - \theta) = \frac{1}{n^2}$$

则,

$$\begin{aligned} E(\hat{\theta}_1) &= E(X_{(1)}) = \theta + \frac{1}{n} \neq \theta \\ \text{Var}(\hat{\theta}_1) &= \text{Var}(X_{(1)}) = \text{Var}(X_{(1)} - \theta) = \frac{1}{n^2} \end{aligned}$$

故 $\hat{\theta}_1 = X_{(1)}$ 不是 θ 的无偏估计。

由于,

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_1) = \lim_{n \rightarrow \infty} \left(\theta + \frac{1}{n} \right) = \theta, \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_1) = \lim_{n \rightarrow \infty} \frac{1}{n^2} = 0$$

故 $\hat{\theta}_1 = X_{(1)}$ 是 θ 的相合估计;

(b). 总体 X 的密度函数为

$$p(x; \theta) = e^{-(x-\theta)}, x > \theta$$

有 $X - \theta$ 服从指数分布 $\text{Exp}(1)$ 。

则 $E(X - \theta) = E(X) - \theta = 1$, 即 $\theta = E(X) - 1$, 故 θ 的矩估计 $\hat{\theta}_2 = \bar{X} - 1$ 。

因,

$$E(X) = \theta + 1, \quad \text{Var}(X) = \text{Var}(X - \theta) = \theta^2$$

则,

$$E(\hat{\theta}_2) = E(\bar{X}) - 1 = E(X) - 1 = \theta, \quad \text{Var}(\hat{\theta}_2) = \text{Var}(\bar{X}) = \frac{1}{n} \text{Var}(X) = \frac{\theta^2}{n}$$

故 $\hat{\theta}_2 = \bar{X} - 1$ 是 θ 的无偏估计。

因,

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_2) = \theta, \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_2) = \lim_{n \rightarrow \infty} \frac{\theta^2}{n} = 0$$

故 $\hat{\theta}_2 = \bar{X} - 1$ 是 θ 的相合估计。

10 证明. 若只有一个观测值 x , 似然函数为

$$L(\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

对于任一固定的 σ , 当 $\mu = x$ 时, $L(\mu)$ 取得最大值 $\frac{1}{\sqrt{2\pi\sigma}}$ 。

由于 $\frac{1}{\sqrt{2\pi\sigma}}$ 关于 σ 单调递减, 且

$$\lim_{\sigma \rightarrow 0} \frac{1}{\sqrt{2\pi\sigma}} = \infty$$

即 $\frac{1}{\sqrt{2\pi\sigma}}$ 不存在最大值, 故 μ, σ^2 的最大似然估计不存在。